

Optimización de planes de radioterapia de intensidad modulada mediante metaheurísticas: comparación entre Algoritmo Genético, Optimizador de Lobo Gris y un esquema híbrido

Naomi Otero Flores, Arely Lopez Perez, Omar Rodriguez Cortes, Octavio Misael Xochihua Bautista

Benemérita Universidad Autónoma de Puebla, Facultad de Ciencias de la Computación, Puebla, México.

Resumen. La planificación manual de radioterapia de intensidad modulada (IMRT) para cáncer de cabeza y cuello consume entre dos y cinco horas por paciente y depende de la experiencia del oncólogo. Este trabajo evalúa tres metaheurísticas —Algoritmo Genético (AG), Optimizador de Lobo Gris (GWO) y un híbrido secuencial AG-GWO— para optimizar las intensidades de nueve haces de radiación. Se emplearon 20 pacientes reales del conjunto OpenKBP y 10 corridas independientes por algoritmo. Los tres métodos alcanzaron planes clínicamente comparables (aptitud media 0.242), con la médula espinal por debajo del límite de 45 Gy. La prueba de Wilcoxon pareada mostró que el híbrido supera significativamente al GWO ($p < 0.001$), mientras que el GWO converge más rápido en las primeras iteraciones. Los resultados respaldan el uso de metaheurísticas como apoyo a la planificación automática de radioterapia.

Palabras Clave: Radioterapia, Metaheurísticas, Algoritmo Genético, Optimizador de Lobo Gris, Optimización Multiobjetivo, OpenKBP.

1 Introducción

El cáncer de cabeza y cuello representa uno de los escenarios más complejos para la radioterapia debido a la proximidad del tumor con estructuras críticas como la médula espinal, las glándulas parótidas y el tronco encefálico. La radioterapia de intensidad modulada (IMRT) permite depositar dosis elevadas sobre el volumen tumoral conformando la radiación desde múltiples ángulos, pero la calidad del plan depende de un proceso de planificación inversa que un físico médico ajusta manualmente durante varias horas.

La planificación manual presenta dos limitaciones: el tiempo requerido, que oscila entre dos y cinco horas por paciente, y la variabilidad inter-observador, ya que el resultado depende de la experiencia de quien lo elabora. En este contexto, las metaheurísticas ofrecen una alternativa capaz de generar planes consistentes en segundos, lo que constituye un impacto clínico medible.

Este trabajo compara tres metaheurísticas para optimizar las intensidades de los haces en IMRT: el Algoritmo Genético (AG), el Optimizador de Lobo Gris (GWO) y un esquema híbrido AG-GWO propuesto por los autores. La contribución principal es una evaluación cuantitativa, con validación estadística pareada, sobre datos clínicos reales del conjunto OpenKBP, así como el análisis de la calidad clínica de los planes resultantes mediante histogramas dosis-volumen.

2 Marco teórico

2.1 Conjunto de datos OpenKBP

OpenKBP es un conjunto de datos público publicado para el Open Knowledge-Based Planning Challenge 2020 [1]. Contiene 340 pacientes de cáncer de cabeza y cuello tratados con IMRT de 6 MV, divididos en 200 de entrenamiento, 40 de validación y 100 de prueba. Cada paciente se representa como una rejilla tridimensional de $128 \times 128 \times 128$ vóxeles, donde cada vóxel mide aproximadamente $3.9 \times 3.9 \times 2.5$ mm. Los datos vienen preprocesados en formato CSV disperso, lo que evita el procesamiento de archivos DICOM.

Para cada paciente se proporcionan la dosis del plan clínico real, la tomografía computarizada y las máscaras de las estructuras anatómicas. Las máscaras se almacenan como listas de índices de vóxeles, mientras que la dosis se almacena como pares índice-valor en grays (Gy).

2.2 Metaheurísticas

El *Algoritmo Genético* [2] es una técnica evolutiva inspirada en la selección natural, que evoluciona una población de soluciones mediante operadores de selección, cruce y mutación. El *Optimizador de Lobo Gris* (GWO) [3] imita la jerarquía social y la estrategia de caza de los lobos grises, donde los tres mejores individuos (alfa, beta y delta) guían el movimiento del resto de la manada. Ambos pertenecen a la familia de algoritmos basados en población y han mostrado buen desempeño en problemas de optimización continua de alta dimensión.

3 Metodología

3.1 Representación del problema

Cada solución candidata (un plan de tratamiento) se representa como un vector de nueve pesos $w = (w_1, w_2, \dots, w_9)$, donde cada $w_i \in [0, 1]$ representa la intensidad relativa del haz situado en uno de los nueve ángulos equiespaciados del isocentro ($0^\circ, 40^\circ, 80^\circ, \dots, 320^\circ$), configuración estándar en IMRT [5].

3.2 Función de aptitud

La calidad de un plan se evalúa mediante una función de aptitud multiobjetivo que premia la cobertura tumoral y penaliza la dosis en los órganos en riesgo, según la ecuación (1):

$$f = \alpha \cdot D95 - \beta \cdot D_{\text{mean}}(\text{OAR}) - \gamma \cdot \max(0, D_{\text{max}} - L_{\text{médula}}) \quad (1)$$

donde $D95$ es la dosis que recibe el 95 % del volumen tumoral (objetivo ≥ 70 Gy), el segundo término es la dosis media normalizada en los órganos en riesgo y el tercero penaliza el exceso sobre el límite clínico de la médula espinal [4]. Los coeficientes empleados fueron $\alpha = 1.0$, $\beta = 0.5$ y $\gamma = 2.0$. La distribución de dosis se simula combinando núcleos gaussianos por haz, anclados a la dosis del plan clínico real para respetar la geometría anatómica del paciente.

3.3 Algoritmos comparados

El AG emplea selección por torneo ($k = 3$), cruce de un punto, mutación gaussiana (probabilidad 0.05) y elitismo. El GWO actualiza la posición de cada lobo en función de los líderes alfa, beta y delta, con un parámetro de exploración que decrece linealmente de 2 a 0. El híbrido AG-GWO ejecuta primero el AG durante la mitad del presupuesto de iteraciones para explorar el espacio de búsqueda, y luego inicializa el GWO con la población evolucionada del AG para refinar la solución, combinando la exploración del primero con la explotación del segundo.

El siguiente fragmento resume el cálculo de la función de aptitud:

Algoritmo 1. Cálculo de la función de aptitud de un plan.

```
def calcular_fitness(pesos, paciente, a=1.0, b=0.5, g=2.0):
    dosis = simular_distribucion_dosis(pesos, paciente)
    D95 = paciente.calcular_D95(dosis)
    danio = dosis_media_normalizada_OARs(dosis, paciente)
    dmax = paciente.calcular_Dmax_oar('SpinalCord', dosis)
    pen = max(0, dmax - 45) / 45
    return a*(D95/70) - b*danio - g*pen
```

3.4 Diseño experimental

Se seleccionaron 20 pacientes del conjunto de prueba. Cada algoritmo se ejecutó 10 veces por paciente con semillas distintas, generando 200 observaciones por algoritmo. Cada ejecución utilizó una población de 50 individuos durante 80 generaciones (en el híbrido, 40 generaciones de AG seguidas de 40 iteraciones de GWO, garantizando el mismo presupuesto). Para acelerar la evaluación se construyó una caché de la región de interés que reduce el cómputo a los aproximadamente 6 000 vóxeles del tumor y los órganos en riesgo, en lugar de los 2.1 millones de la rejilla completa.

La comparación estadística entre algoritmos se realizó con la prueba de Wilcoxon de rangos con signo pareada, emparejando observaciones por paciente y corrida, con un nivel de significancia de 0.05.

4 Resultados y discusión

4.1 Comparación de la aptitud

La Tabla 1 resume la aptitud final de las 200 observaciones por algoritmo. Los tres métodos alcanzan medias prácticamente idénticas, con el híbrido ligeramente superior. La elevada desviación estándar no refleja inestabilidad de los algoritmos, sino la heterogeneidad entre pacientes: los tumores grandes producen aptitudes bajas y los pequeños, altas, independientemente del algoritmo.

Tabla 1. Estadísticos de la aptitud final por algoritmo (n = 200 observaciones).

Algoritmo	Media	Desv. est.	Mediana	Mín.	Máx.
AG	0.2418	0.1006	0.2159	0.0372	0.4459
GWO	0.2421	0.1016	0.2142	0.0374	0.4456
Híbrido	0.2427	0.1015	0.2159	0.0373	0.4455




Fig. 1. Distribución de la aptitud final de las 200 observaciones por algoritmo. Las medianas y rangos intercuartílicos son prácticamente equivalentes; los puntos superiores corresponden a pacientes con tumores pequeños.

4.2 Convergencia

La Fig. 2 muestra la evolución de la aptitud a lo largo de las generaciones. El GWO asciende con mayor rapidez durante las primeras diez iteraciones gracias a su jerarquía social, mientras que el AG y el híbrido progresan de forma más gradual hasta alcanzar un nivel equivalente. Esto confirma que el GWO es más eficiente en explotación temprana, mientras que el AG aporta mayor diversidad exploratoria.




Fig. 2. Curvas de convergencia promedio de los tres algoritmos. El GWO converge más rápido en las primeras iteraciones; los tres alcanzan un nivel final equivalente.

4.3 Calidad clínica de los planes

La Tabla 2 presenta las métricas clínicas promedio de los mejores planes. Los tres algoritmos mantienen la médula espinal ($D_{max} \approx 38$ Gy) y el tronco encefálico muy por debajo de sus límites, lo que garantiza la seguridad del plan. La cobertura tumoral ($D_{95} \approx 49$ Gy) queda por debajo de la meta de 70 Gy, una limitación atribuible al simulador simplificado de nueve haces; la dosis media en las parótidas excede ligeramente el límite de 26 Gy.

Tabla 2. Métricas clínicas promedio por algoritmo frente a los límites de QUANTEC/DAHANCA.

Métrica (límite)	AG	GWO	Híbrido	Estado
D_{95} tumor (≥ 70 Gy)	49.1	48.6	49.2	Subóptimo
D_{max} médula (≤ 45 Gy)	38.2	37.0	38.0	Cumple
D_{mean} parótida izq. (≤ 26 Gy)	27.6	27.1	27.6	Al límite
D_{max} tronco encef. (≤ 54 Gy)	25.1	24.2	25.0	Cumple




Fig. 3. Histograma dosis-volumen (DVH) del mejor plan de cada algoritmo para un paciente representativo. La curva roja (tumor) cae cerca de la dosis prescrita, mientras que las curvas de los órganos en riesgo se mantienen a dosis bajas.

4.4 Validación estadística

La Tabla 3 muestra los resultados de la prueba de Wilcoxon pareada. El híbrido supera al GWO de forma estadísticamente significativa ($p < 0.001$), lo que valida la utilidad de combinar ambas metaheurísticas. La diferencia entre AG y GWO se sitúa en el límite de significancia ($p = 0.052$), mientras que entre AG e híbrido no es significativa. Las diferencias absolutas son pequeñas pero, al disponer de 200 pares, resultan detectables.

Tabla 3. Prueba de Wilcoxon pareada entre algoritmos ($n = 200$ pares).

Comparación	Valor p	¿Significativo?	Mejor algoritmo
-------------	---------	-----------------	-----------------

AG vs GWO	0.052	No	GWO (marginal)
AG vs Híbrido	0.510	No	Híbrido
GWO vs Híbrido	< 0.001	Sí	Híbrido

5 Conclusiones y trabajos futuros

Se compararon tres metaheurísticas para la optimización de planes de IMRT sobre datos clínicos reales del conjunto OpenKBP. Los tres algoritmos generan planes de calidad equivalente, manteniendo los órganos críticos dentro de límites seguros, lo que demuestra la viabilidad de las metaheurísticas como apoyo a la planificación automática. El híbrido AG-GWO mostró una ventaja estadísticamente significativa sobre el GWO, mientras que el GWO ofreció la convergencia más rápida.

Como trabajo futuro se plantea aumentar el número de haces (de 9 a 36 o 72) y modelar el colimador multiláminas, lo que ampliaría el espacio de búsqueda y permitiría apreciar con mayor claridad las diferencias entre algoritmos. Asimismo, se propone sustituir el simulador gaussiano por un cálculo de dosis basado en métodos de Monte Carlo para incrementar la validez clínica, y escalar el estudio a los 100 pacientes del conjunto de prueba.

Agradecimientos. Los autores agradecen a la Benemérita Universidad Autónoma de Puebla y a los organizadores del Open Knowledge-Based Planning Challenge por la disponibilidad pública del conjunto de datos OpenKBP.

Referencias

1. Babier, A.; Zhang, B.; Mahmood, R.; Moore, K.L.; Purdie, T.G.; McNiven, A.; Chan, T.C.Y.: OpenKBP: The open-access knowledge-based planning grand challenge and dataset. *Medical Physics*, Vol. 48, No. 9, pp. 5549-5561 (2021)
2. Holland, J.H.: *Adaptation in Natural and Artificial Systems*. University of Michigan Press, Ann Arbor (1975)
3. Mirjalili, S.; Mirjalili, S.M.; Lewis, A.: Grey Wolf Optimizer. *Advances in Engineering Software*, Vol. 69, pp. 46-61 (2014)
4. Marks, L.B.; Yorke, E.D.; Jackson, A.; Ten Haken, R.K.; Constine, L.S.; Eisbruch, A.; et al.: Use of normal tissue complication probability models in the clinic. *International Journal of Radiation Oncology Biology Physics*, Vol. 76, No. 3, pp. S10-S19 (2010)
5. Webb, S.: The physical basis of IMRT and inverse planning. *The British Journal of Radiology*, Vol. 76, No. 910, pp. 678-689 (2003)