

Optimización de Planes de Radioterapia

usando Algoritmo Genético y Lobo Gris (GWO)

10M+

pacientes de cáncer tratados
con radioterapia cada año

2–5 hrs

que tarda un oncólogo en
planificar un tratamiento manual

¿Cuál es el problema?

El reto clínico

La radioterapia destruye tumores con rayos de alta energía.

El problema: los rayos también dañan tejido sano. Un buen plan debe:

Maximizar la dosis en el tumor (PTV)

Minimizar la dosis en órganos sanos (OARs)

Hoy esto lo hace manualmente un oncólogo: toma 2–5 horas y depende de su experiencia. Errores en el plan pueden reducir la efectividad del tratamiento.

¿Por qué inteligencia artificial?

1

El espacio de soluciones es enorme — millones de combinaciones posibles de ángulos y dosis.

2

No existe una fórmula matemática directa para encontrar el plan óptimo.

3

Las metaheurísticas (AG, GWO) son ideales para explorar espacios grandes sin necesitar derivadas.

4

Un sistema automatizado garantiza consistencia — sin depender de la experiencia del planificador.

¿Por qué importa?

El cáncer es la 2ª causa de muerte mundial. La radioterapia es parte del tratamiento en más del 50% de los casos.

10M+

pacientes al año
reciben radioterapia

50%

de pacientes con cáncer
necesitan radioterapia

2–5h

por plan manual
vs minutos con IA

30%

de planes subóptimos
por variabilidad humana

Impacto industrial directo:

Un sistema automatizado de planificación puede reducir el tiempo de 5 horas a minutos, aumentar la consistencia de los planes y potencialmente mejorar la supervivencia de pacientes.

El dataset: OpenKBP

Historia y origen

OpenKBP fue creado para el Open Knowledge-Based Planning Challenge, una competencia científica internacional organizada en 2020. 340 pacientes con cáncer de cabeza y cuello fueron tratados con radioterapia IMRT (Intensity-Modulated Radiation Therapy) de 6 MV en hospitales reales. Los datos fueron anonimizados (sin información personal) y publicados para uso en investigación. Hoy es uno de los datasets estándar en IA aplicada a oncología.

340 pacientes

Cáncer de cabeza y cuello tratados con IMRT

CT volumétrico

Imágenes 3D de anatomía del paciente por vóxel

Estructuras

PTV (tumor) + 7 OARs (médula, parótidas, mandíbula...)


Dosis real

La distribución de dosis validada por oncólogos clínicos

Acceso: github.com/ababier/open-kbp · Formato CSV, sin necesidad de instalar librerías especiales · Uso libre para investigación

Los datos ya están preprocesados: no necesitan convertir imágenes DICOM. Se trabaja directamente con matrices de dosis y coordenadas de estructuras.

¿Cómo se construye el programa?



Módulos del programa

`entorno.py`

Carga los datos de OpenKBP. Normaliza dosis y coordenadas. Provee la función de evaluación del plan.

`fitness.py`

Calcula: $\alpha \cdot D_{\text{tumor}} - \beta \cdot D_{\text{OARs}}$. Retorna el score de calidad de un plan dado.

`genetico.py`

Implementa selección por torneo, cruce en un punto y mutación gaussiana sobre vectores de pesos.

`gwo.py`

Implementa la jerarquía $\alpha/\beta/\delta/\omega$ del Lobo Gris. Actualiza posiciones por promedio de los tres mejores lobos.

`experimento.py`

Corre N repeticiones de AG y GWO. Guarda curvas de fitness. Genera gráficas de convergencia y comparación.

Algoritmo Genético (AG)

Analogía:

igual que en la evolución natural, los mejores "individuos" (planes de dosis) sobreviven y se reproducen, generando planes cada vez mejores.

Inicialización

Se crean 50 cromosomas aleatorios. Cada cromosoma es un vector de pesos: $[w_1, w_2, \dots, w_9]$ donde $w_i \in [0, 1]$

Selección por torneo

Se eligen pares de cromosomas al azar. El que tenga mayor fitness pasa a la siguiente generación.

Cruce (crossover)

Dos cromosomas 'padre' intercambian genes en un punto aleatorio: $\text{padre1}[:k] + \text{padre2}[k:]$

Mutación

Con probabilidad $p=0.05$, se suma un ruido gaussiano $N(0,0.1)$ a un gen aleatorio del cromosoma.

$$\text{Fitness} = \alpha \cdot D_{\text{tumor}} - \beta \cdot D_{\text{OARs}} - \gamma \cdot \text{penalización_sobredosis}$$

Optimizador de Lobo Gris (GWO)

Jerarquía de la manada:

α (Alpha)

El mejor plan encontrado. Lidera.

β (Beta)

2° mejor. Apoya al alpha.

δ (Delta)

3° mejor. Refuerza la búsqueda.

ω (Omega)

El resto — exploran el espacio.

Cómo se mueven los lobos ω :

$$X_1 = X\alpha - A_1 \cdot |C_1 \cdot X\alpha - X|$$

$$X_2 = X\beta - A_2 \cdot |C_2 \cdot X\beta - X|$$

$$X_3 = X\delta - A_3 \cdot |C_3 \cdot X\delta - X|$$

$$X(t+1) = (X_1 + X_2 + X_3) / 3$$

Donde A y C son coeficientes que balancean exploración y explotación, y disminuyen linealmente con las iteraciones.

Diferencia clave vs AG:

No hay cruce de genes. En lugar de mezclar soluciones aleatoriamente, cada lobo ω se mueve hacia el promedio de los 3 mejores planes encontrados hasta ese momento. Tiende a converger más rápido pero con menos diversidad.

Nuestra propuesta: híbrido AG-GWO

ORIGINAL

Idea: usar AG al inicio para explorar ampliamente, luego GWO para afinar la convergencia.

Fase 1 (Gen. 1–50)

AG — Exploración

Operadores genéticos generan diversidad. Cruce y mutación exploran amplias regiones del espacio.



Fase 2 (Gen. 51–100)

GWO — Explotación

Las mejores soluciones del AG se convierten en α , β y δ . GWO afina y converge hacia el óptimo.

Hipótesis que validaremos:

AG puro explora mejor (mayor diversidad inicial) | **GWO puro** converge más rápido | **Híbrido** combina ambas ventajas → mejor fitness final

Plan experimental

50

Población
individuos

100

Generaciones
por corrida

10

Repeticiones
corridas

5%

Tasa de mutación
probabilidad

30

Pacientes a evaluar
del dataset

Métricas de evaluación (estándar clínico)

D95

Dosis que recibe el 95% del volumen tumoral. Mide qué tan bien se cubre el tumor.

Dmean (OARs)

Dosis promedio en órganos en riesgo. Mide cuánto daño se hace a tejido sano. Queremos que este sea lo mas bajo posible

Fitness final

Valor de la función objetivo al término de las generaciones. Comparado entre AG, GWO e híbrido. Donde el eje X son las generaciones y el eje Y son el mejor fitness

Curva de convergencia

Gráfica del fitness mejor vs. generación. Muestra velocidad de aprendizaje de cada algoritmo.

Glosario de términos clave

PTV

Planning Target Volume — el volumen del tumor que debe recibir la dosis completa de radiación.

OAR

Organ At Risk — órganos sanos cercanos al tumor que deben protegerse (médula espinal, parótidas, etc.).

Vóxel

Píxel en 3D. La imagen CT divide el cuerpo en miles de vóxeles, cada uno con un valor de densidad.

DVH

Dose-Volume Histogram — gráfica clínica que muestra qué % del volumen recibe cierta dosis.

IMRT

Intensity-Modulated Radiation Therapy — técnica que varía la intensidad de cada haz de radiación.

D95

La dosis que recibe al menos el 95% del tumor. Indicador clave de cobertura tumoral.

Metaheurística

Algoritmo de búsqueda general inspirado en la naturaleza, que encuentra buenas soluciones sin garantizar el óptimo absoluto.

Cromosoma

En AG, la representación de una solución — en este caso, un vector de pesos de los haces de radiación.

Fitness

Función que califica qué tan buena es una solución. Mayor fitness = mejor plan de radioterapia.

Resumen del proyecto

Optimización de radioterapia con IA

Problema real:	Planificación manual = 2–5 hrs, variabilidad humana
Dataset:	OpenKBP — 340 pacientes, acceso libre en GitHub
Técnicas:	AG, GWO, e Híbrido AG-GWO (propuesta original)
Métricas:	D95, Dmean, curvas de convergencia, Wilcoxon
Impacto:	Reducción de tiempo de planeación de horas a minutos